

一、 可解釋 AI (XAI) 核心概念與限制說明

在評估本專題的 RAG 財報問答系統時，除了正確率，我們也必須關注模型的可解釋性 (Explainability)。以下為三種常見 XAI 概念與限制分析：

- 1. **Feature Importance (特徵重要性)**：在傳統機器學習（如隨機森林）中，可直觀看出哪些變數（如營收、毛利率）對預測結果影響最大。但在 LLM 生成任務中，難以用單一數值量化詞彙對整句生成的貢獻。
- 2. **LIME / SHAP 的直覺**：這兩者透過局部微調輸入來觀察輸出的變化，藉此推斷模型依賴哪些特徵。若應用於 RAG，可藉由遮蔽某些檢索段落（Masking）來測試 LLM 是否真的依賴該段落回答，還是憑藉自身預訓練記憶（幻覺）。
- 3. **Attention 不等於 Explanation (注意力不等於解釋)**：在 Transformer 架構中，Attention 權重只代表詞彙間的數學關聯程度，不代表人類邏輯上的因果解釋。因此，在財報系統中，即使 LLM 對某個數字給予高 Attention，我們仍必須要求它輸出明確的財報頁碼作為外部依據，而不能僅靠 Attention 權重來證明其正確性。

二、 RAG 系統錯誤分析表

案例	原始輸入或問題	錯誤現象	可能來源 (4 大類)	影響	改進方式
E 1	跨段落整合：資	AI 找到支出金額與借款用途，但無法逐項對應。	檢索限制 (Chunking 切塊中斷上下文)	回答不夠深入，失去財務關聯性。	導入 Parent-Child Document Retriever 保留段落階層。

	本支出與借款用途對應				
E 2	表格內的研發費用金額？	數字抓取正確，但年份或項目對錯列。	資料處理 (PDF 表格解析破碎)	給出錯誤的財務數字。	改用具備表格結構解析的工具 (如 pdfplumber/Markdown 轉換)。
E 3	2026 年第三季的預期毛利	AI 雖然回答未明確說明，但在早期測試時曾試圖用歷史平均推測。	Prompt 生成 (LLM 過度推論傾向)	產生幻覺，誤導投資決策。	強制加入「嚴禁推測，未提及直接回答不知道」的 System Prompt。

	率？				
E 4	短期租賃是否適用相同認列條件？	財報未提短期租賃豁免，AI 直接回答不知道。	資料來源 (單一文件知識不足)	顯得不夠專業，不符會計實務。	擴充 RAG 知識庫，加入「IFRS 國際財務報導準則」文件。
E 5	匯率波動對淨利的影響金額？	AI 給出敏感度分析的金額，未強調是「假設性」虧損。	Prompt 生成 (財務名詞語意理解不足)	使用者誤以為公司實際發生該筆虧損。	在 Prompt 增加「遇敏感度分析需強制標示為假設情境」的規則。

E 6	財報裡的研發費用是多少？	AI 僅回答數字，未標示時間區間與佔比。	使用者問題 (Query 過於簡略)	資訊斷章取義。	前端介面導入 Query Rewriting Agent，自動擴充使用者提問。
E 7	測試腳本自動評估正確率	LLM 回答「約 1 兆 2 千億」，被系統判定與「1,270,380,250 仟元」不符 (Exact Match 失敗)。	評估指標 (Metric 過於死板)	系統 Accuracy 虛低。	捨棄字串比對，改用 LLM-as-a-Judge 進行語意相似度評分。
E 8	大量批次詢問 20 題	出現 429 RESOURCE_EXHAUSTED 或 404 錯誤。	系統環境 (API Rate Limit/模型版本過期)	系統中斷無法服務。	程式碼加入 <code>time.sleep</code> 延遲機制，並定期更新模型版本 API。

	問題				
--	----	--	--	--	--

三、 AI 論文拆解表

RAGAS: Automated Evaluation of Retrieval Augmented Generation

欄位	應填內容 (以 RAGAS 論文為例)
題名與來源	RAGAS: Automated Evaluation of Retrieval Augmented Generation (Es et al., 2023, 發表於 arXiv / EACL)
研究問題	作者想解決：RAG 系統缺乏無需人工標註的標準化自動評估工具。這很重要，因為傳統指標 (如 BLEU) 無法有效衡量 RAG 的「檢索品質」與「生成依據性」。
資料集與情境	使用 WikiQA、FiQA (金融問答資料集) 等開放資料集，針對 RAG 在問答任務上的表現進行評估測試。
方法與模型	提出 RAGAS 框架，完全無需人工標籤，利用強大 LLM (如 GPT-4) 進行無參考 (Reference-free) 評分。評分三大構面：Faithfulness (忠實度/依據性)、Answer Relevance (回答相關性)、Context Relevance (檢索上下文相關性)。
Baseline (比較對象)	與傳統的字串/語意比對指標 (如 Exact Match, ROUGE, BERTScore) 以及真人標註的品質分數進行相關性比較。
Metrics (評估指標)	使用 Pearson / Spearman 相關係數，證明 RAGAS 給出的分數與人類專家評分的高度一致性。
Ablation / 穩健性	測試了替換不同底層 LLM (如 GPT-3.5 替換為 Claude) 作為評判者時，RAGAS 分數的穩定性變化。
Limitation (限制)	作者承認：嚴重依賴作為評判者的 LLM 能力。如果底層 LLM 本身有偏見或幻覺，RAGAS 的評分也會不準確。

可改進處	若由自己延伸，可補上「中文財報情境」的實驗，測試 RAGAS 對於高度結構化表格與中文財會專有名詞的評估準確度。
------	--

四、對自身專題的改進建議與研究意識

綜合錯誤分析與 RAGAS 論文的啟發，若將本專題進一步發展為正式研究，提出以下 3 個改進方向：

1. **重新設計評估指標 (Metrics 改進)：**目前的測試表多仰賴人工主觀判斷 ( / )。未來應導入類似 RAGAS 的自動化評估框架，將正確性細分為「生成忠實度 (Faithfulness)」與「答案相關性 (Relevance)」，以量化分數取代二分法。
2. **補強資料處理實驗 (Data 改進)：**針對財報中的跨頁表格與附註，單純的 Recursive Text Splitter 會破壞結構。未來需補充「Markdown 結構化解析」與「Graph RAG (知識圖譜)」的對照實驗，比較檢索精準度的提升。
3. **補充人工與防幻覺實驗 (Ablation 改進)：**設計消融實驗 (Ablation Study)，比較「有加入防幻覺 System Prompt」與「無 Prompt」時的錯誤率差異；同時針對財會情境，需考慮 IRB 規範，邀請具備商管背景的受測者進行盲測，驗證系統在真實決策場景中的安全性。